ENTREGABLE 3: ANÁLISIS DE DATOS

Peso 20 %

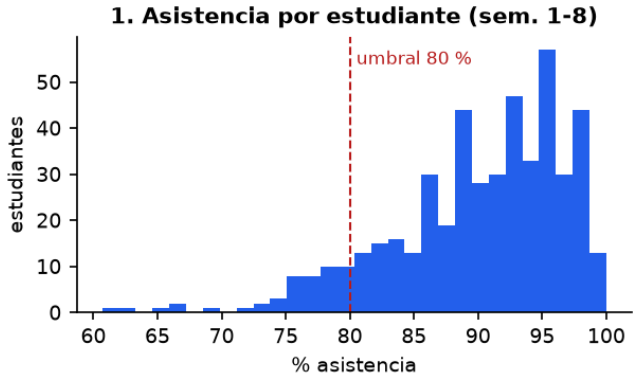
Complejidad: media | Sesiones 5-6 | Python: Pandas, Matplotlib | Archivos: 03_ANALISIS_DATOS.xlsx + .pdf

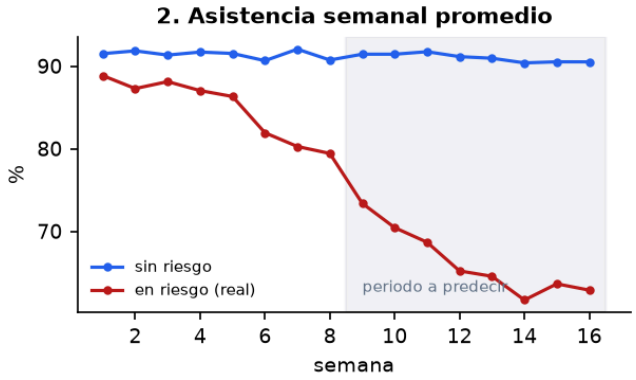
Origen de los datos. School_Plus entró en uso este semestre y aún no tiene un periodo completo cerrado. Para no exponer datos de menores, el análisis usa un **dataset sintético con el esquema exacto de `asistencia_registro`** (480 estudiantes, 60 clases, 16 semanas), generado con supuestos documentados en el notebook. El pipeline lee el CSV que exporta School_Plus, así que se reemplaza por los datos reales sin cambiar código.

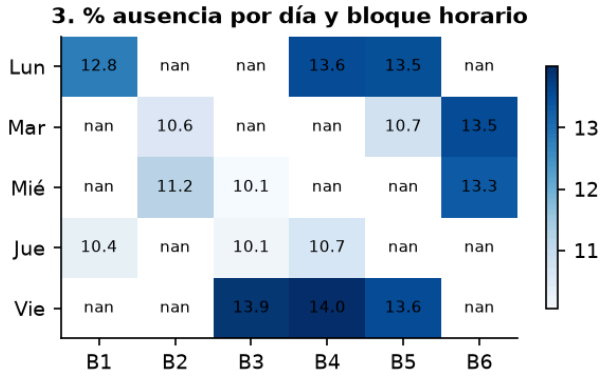
1. Exploración (EDA)

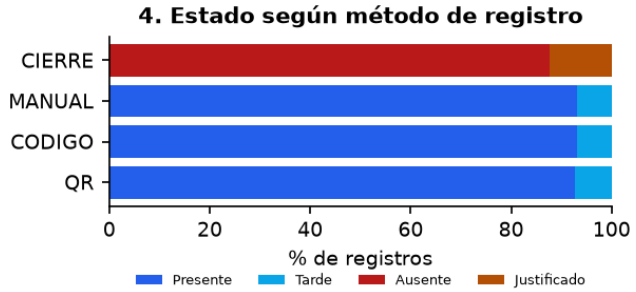
Dimensión	Valor	Hallazgo
Filas × columnas	115 891 × 11	Un registro por estudiante y sesión
Estudiantes / clases	480 / 60	Grados 6.° a 11.°, grupos A (mañana) y B (tarde)
Tipos	8 categóricas, 3 numéricas	estado y método son categorías cerradas (CHECK en BD)
Duplicados	691 (0,6 %)	Dos exportaciones con rangos de fechas solapados
Nulos `observacion`	98,3 %	Estructural: solo existe en justificadas
Nulos `dispositivo_id`, `ip`	20,9 %	Estructural: registros MANUAL y CIERRE no tienen celular
Distribución de estados	Presente 80,2 % · Ausente 11,9 % · Tarde 6,3 % · Justificado 1,7 %	
Distribución de métodos	QR 68,1 % · Cierre 13,6 % · Código 11,0 % · Manual 7,3 %	

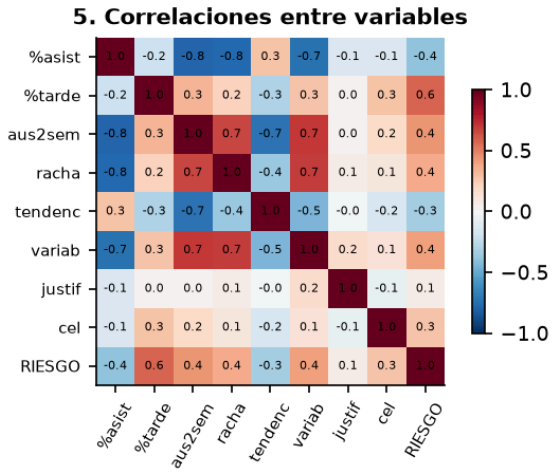
2. Visualizaciones

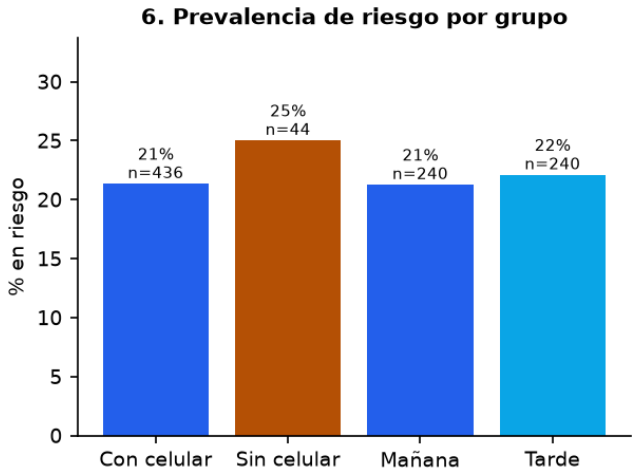












G1: la mayoría está sobre 90 %, con una cola bajo el umbral. G2: quienes terminan en riesgo ya vienen cayendo antes de la semana 8: hay señal para predecir. G3: más ausencia en lunes, viernes y último bloque. G4: CIERRE concentra las ausencias; MANUAL corresponde a estudiantes sin celular. G5: la tardanza es la variable más correlacionada con el riesgo (0,58). G6: prevalencia por grupo.

3. Limpieza (documentada)

Transformación	Motivo
Eliminar 691 filas duplicadas → 115 200	Exportaciones solapadas inflaban las ausencias
Mantener nulos estructurales (no imputar)	Un MANUAL sin celular no es un dato faltante
Eliminar la columna `ip`	Dato personal sin valor predictivo (minimización)
Variables derivadas: asistió, cuenta, tarde, ausente	Mismo cálculo que School_Plus: (presentes + tardes) / (total − justificadas)
Agregar por estudiante: semanas 1-8 → variables; 9-16 → etiqueta	Evitar fuga de información del futuro

4. Estadísticas clave

Asistencia media **90,0 %** (mediana 91,6 %, percentil 10: 80,5 %). Tardanza media 7,5 % de las asistencias. **104 de 480 estudiantes (21,7 %)** terminan en riesgo. Correlación con el riesgo: tardanza **+0,58**, % asistencia −0,39, tendencia semanal −0,32, cambios de celular +0,27.

5. Sesgos iniciales

- **Desbalance de clases:** 21,7 % positivos → se usa `class_weight="balanced"` y se mide recall/F1, no exactitud.
- **Sesgo de registro en estudiantes sin celular (9,2 %):** su ausencia registrada es 18,6 % contra 11,5 % del resto. Parte de esa diferencia no es ausentismo real: si el docente olvida marcarlo a mano, el cierre lo deja ausente. **La etiqueta misma está sesgada contra este grupo.**
- Jornada: prevalencia similar (mañana 21,2 %, tarde 22,1 %); no hay desequilibrio relevante.

6. Dataset preparado

`data/asistencia_limpio.csv` (115 200 registros) y `data/dataset_modelo_limpio.csv` (480 estudiantes × 9 variables + etiqueta + atributos de grupo solo para auditoría).