Alerta temprana de ausentismo escolar con aprendizaje automático: diseño y prototipo sobre una plataforma de asistencia con código QR

Leidy Carolina Aponte

Fundación de Educación Superior San José

Opción de Grado: Inteligencia Artificial (Diplomado)

Ing. Winder Osorio Villalobos

27 de octubre de 2026

Resumen

El ausentismo escolar es uno de los predictores más consistentes de la reprobación y la deserción, pero en muchas instituciones se detecta cuando el daño ya está hecho. Este artículo presenta el diseño y el prototipo de un sistema de alerta temprana construido sobre School_Plus, una plataforma escolar que registra la asistencia mediante códigos QR dinámicos. A partir de los registros de asistencia de las primeras ocho semanas de un periodo académico, se entrenó un clasificador Random Forest que estima qué estudiantes terminarán las ocho semanas siguientes con una asistencia inferior al 80 %. Se usó un conjunto de datos sintético de 115 200 registros (480 estudiantes) con el esquema exacto de la plataforma, para no exponer datos de menores. En el conjunto de prueba, el modelo identificó el 87 % de los estudiantes en riesgo (AUC = 0,90), frente al 52 % de la regla manual que aplica coordinación. La evaluación por grupos reveló un sesgo de registro que afecta a los estudiantes sin teléfono celular, y se proponen medidas para mitigarlo. Se concluye que la IA aporta valor cuando se integra a un flujo institucional con supervisión humana, explicabilidad y protección de datos.

Palabras clave: ausentismo escolar, alerta temprana, aprendizaje automático, Random Forest, ética de la IA

Alerta temprana de ausentismo escolar con aprendizaje automático

La inasistencia a clase no es solo un problema disciplinario: es una señal anticipada de riesgo académico. Balfanz y Byrnes (2012) mostraron que el ausentismo crónico, entendido como perder el 10 % o más de los días lectivos, se asocia con menor rendimiento y mayor probabilidad de abandonar la escuela. Allensworth y Easton (2007), por su parte, encontraron que la asistencia en el primer año de secundaria predice la graduación mejor que el rendimiento previo.

En la institución de este estudio, la asistencia se registra con School_Plus, una plataforma desarrollada en Spring Boot y MySQL en la que el docente proyecta un código QR firmado criptográficamente que rota cada 15 segundos. El estudiante lo escanea desde su celular vinculado y, al cerrar la sesión, quien no se registró queda ausente. El problema ya no es capturar el dato, sino interpretarlo a tiempo: coordinación revisa los reportes exportados a Excel de forma manual y aplica una regla informal (alertar si el estudiante tiene menos del 85 % o tres fallas seguidas). Cuando la alerta llega, el estudiante suele estar ya por debajo del umbral académico del 80 %.

El objetivo de este trabajo es diseñar, prototipar y evaluar un modelo que, en la semana 8 de un periodo de 16 semanas, identifique a los estudiantes que terminarán el periodo con una asistencia inferior al 80 %, con una sensibilidad mínima del 80 % y un desempeño superior al de la regla manual. También se evalúan sus implicaciones éticas y su viabilidad.

Marco conceptual

Los sistemas de alerta temprana en educación combinan indicadores de asistencia, conducta y rendimiento para priorizar intervenciones (Allensworth & Easton, 2007). El aprendizaje automático permite pasar de reglas fijas a modelos que ponderan varias señales a la vez. Random Forest (Breiman, 2001) combina cientos de árboles de decisión entrenados sobre muestras aleatorias de los datos y de las variables; es robusto con pocos datos y mide la importancia de cada variable. La regresión logística se usa como modelo de contraste, porque sus

coeficientes son directamente interpretables. Ambos se implementaron con Scikit-learn (Pedregosa et al., 2011).

Como los estudiantes en riesgo son minoría, la exactitud global es una métrica engañosa. Saito y Rehmsmeier (2015) recomiendan, para datos desbalanceados, reportar la precisión y la sensibilidad (recall), complementadas con el área bajo la curva ROC. En un sistema de alerta temprana, un falso negativo (un estudiante en riesgo que no se detecta) cuesta mucho más que un falso positivo (una conversación innecesaria), por lo que se prioriza la sensibilidad.

Por último, la literatura sobre equidad algorítmica advierte que un modelo puede reproducir los sesgos de los datos con que se entrena, aunque no use atributos sensibles de forma explícita (Barocas et al., 2023). La UNESCO recomienda que el uso de IA en educación preserve la supervisión humana, la transparencia y la protección de los datos de los estudiantes (Miao et al., 2021). En Colombia, el tratamiento de datos personales, y en especial de los de menores de edad, está regulado por la Ley 1581 de 2012 (Congreso de la República de Colombia, 2012).

Metodología

Datos. Como la plataforma entró en uso este semestre y aún no tiene un periodo completo cerrado, se generó un conjunto de datos sintético con el esquema exacto de la tabla de registros de asistencia de School_Plus: estado (presente, tarde, ausente, justificado), método (QR, código, manual, cierre), día, franja horaria y cambios de celular. Se simularon 480 estudiantes de los grados 6.° a 11.°, 60 clases y 16 semanas, para un total de 115 891 registros. Los supuestos incluyen un 24 % de estudiantes con deterioro progresivo de la asistencia, más ausencias los lunes, los viernes y en el último bloque, y un 10 % de estudiantes sin celular cuya asistencia marca el docente a mano.

Preparación. El análisis exploratorio identificó 691 registros duplicados (0,6 %), originados en exportaciones con rangos de fechas solapados, que se eliminaron. Los valores nulos de celular e IP resultaron estructurales (corresponden a registros manuales y de cierre), por lo que no se imputaron. La IP se eliminó por minimización de datos. Para cada estudiante se calcularon nueve variables sobre las semanas 1-8: porcentaje de asistencia, porcentaje de

tardanza, ausencias en las dos últimas semanas, racha máxima de ausencias, tendencia y variabilidad semanal, faltas justificadas, ausencia en lunes y viernes, y cambios de celular. La variable objetivo se definió con las semanas 9-16 (asistencia < 80 %), lo que evita la fuga de información del futuro. El 21,7 % de los estudiantes resultó en riesgo.

Modelado y evaluación. Los datos se dividieron en entrenamiento (70 %, n = 336) y prueba (30 %, n = 144) de forma estratificada. Se aplicó validación cruzada de cinco particiones y ponderación de clases para compensar el desbalance. Como línea base se tomó la regla manual de coordinación. Además de las métricas técnicas, se revisaron a mano 25 predicciones, se analizaron los errores de mayor confianza y se comparó el desempeño entre grupos (con y sin celular; jornada de mañana y de tarde). El código, el modelo y los datos están disponibles en el repositorio del proyecto (Aponte, 2026).

Resultados

En validación cruzada, Random Forest obtuvo un AUC de 0,919 (DE = 0,015) y la regresión logística, de 0,916 (DE = 0,031). Se eligió Random Forest por su mayor estabilidad y su mayor sensibilidad. La Tabla 1 resume el desempeño en el conjunto de prueba.

Tabla 1

Desempeño en el conjunto de prueba (n = 144; 31 estudiantes en riesgo)

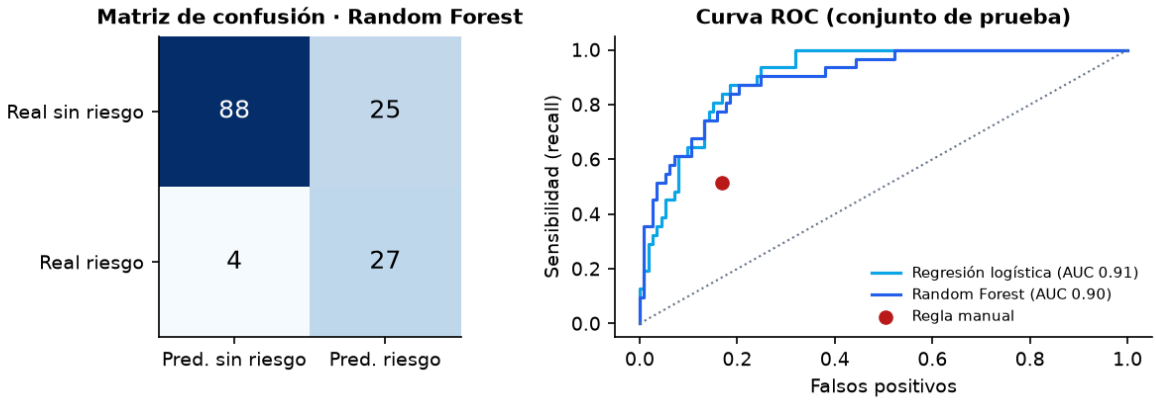
Método	Precisión	Sensibilidad	F1	AUC	Detectados
Regla manual (coordinación)	0,46	0,52	0,49	—	16 de 31
Regresión logística	0,59	0,74	0,66	0,91	23 de 31
Random Forest	0,52	0,87	0,65	0,90	27 de 31

Nota. Umbral de decisión de 0,5. La regla manual alerta cuando la asistencia es menor al 85 % o hay tres ausencias seguidas.

El modelo detectó 11 estudiantes en riesgo más que la regla manual, a cambio de seis falsas alarmas adicionales. La variable más influyente fue el porcentaje de tardanza, seguida de la variabilidad semanal, el porcentaje de asistencia y la tendencia (Figura 1). En la validación manual, 22 de las 25 predicciones fueron correctas; los tres errores fueron falsos positivos de estudiantes que terminaron entre el 80,0 % y el 83,1 %, es decir, en el borde del umbral.

Figura 1

Matriz de confusión y curva ROC del modelo frente a la regla manual



Nota. El punto rojo representa la regla manual: a una tasa similar de falsos positivos, detecta menos casos que el modelo. Elaboración propia.

El análisis de errores mostró dos límites. Primero, un estudiante cuya caída comenzó en la semana 9 no podía ser detectado en la semana 8, porque no había ninguna señal previa. Segundo, un estudiante con una caída fuerte que luego se recuperó apareció como falso positivo, aunque una alerta que dispara una intervención exitosa produce justamente ese patrón. En equidad, la sensibilidad fue de 0,92 para los estudiantes con celular y de 0,60 para los que no tienen, con tasas de falsos positivos de 0,20 y 0,45, respectivamente (n = 16 en este grupo, por lo que la estimación es inestable).

Discusión

Los resultados respaldan la hipótesis de que un modelo entrenado con datos que la plataforma ya captura mejora la detección temprana frente al criterio manual. La importancia de la tardanza coincide con la idea de que el desenganche escolar es gradual (Balfanz & Byrnes, 2012), aunque en este estudio depende de un supuesto de la simulación y debe confirmarse con datos reales.

El hallazgo más relevante es ético. Los estudiantes sin celular tienen más ausencias registradas, no necesariamente porque falten más, sino porque cuando el docente olvida marcarlos a mano el cierre de la sesión los deja ausentes. El modelo aprende de esa etiqueta

sesgada sin usar el atributo “sin celular”, lo que confirma la advertencia de Barocas et al. (2023). Se proponen cuatro medidas: un recordatorio en la plataforma para el marcado manual antes del cierre, verificación humana de las alertas de ese grupo, auditoría de equidad en cada periodo y suspensión del modelo si la brecha supera los 10 puntos porcentuales.

En gobernanza, el modelo recomienda y una persona decide. La alerta llega al docente y a coordinación con los hechos que la explican (por ejemplo, seis ausencias en dos semanas y una tendencia descendente), nunca al estudiante, y se prohíbe usarla para sancionar. El modelo se ejecuta en el servidor del colegio, y la IA generativa, usada para redactar los mensajes a los acudientes, recibe solo resúmenes sin nombres, en línea con la Ley 1581 de 2012 y las recomendaciones de Miao et al. (2021). Con un costo estimado de 80 horas de desarrollo, el ahorro de unas 38 horas mensuales de trabajo docente y de coordinación recuperaría la inversión en menos de tres meses, sin contar el beneficio principal: estudiantes que no abandonan.

La principal limitación es el uso de datos sintéticos. Aunque el esquema es real y el código lee directamente la exportación de la plataforma, las métricas deben recalcularse con el primer periodo real.

Conclusiones

Este trabajo muestra que la inteligencia artificial puede convertir un registro de asistencia en una herramienta de prevención. Un modelo Random Forest, sencillo y ejecutable en la infraestructura existente, duplicó prácticamente la capacidad de detección temprana frente a la regla manual. El aprendizaje central, sin embargo, va más allá de la métrica: el valor de la IA depende de cómo se integra al proceso institucional. Medir el sesgo por grupo, explicar cada alerta y mantener la decisión en manos de docentes y coordinación es lo que permite que la tecnología esté al servicio del problema, y no al revés. El siguiente paso es un piloto en dos grados, en paralelo con la regla manual, para validar los resultados con datos reales.

Referencias

Allensworth, E. M., & Easton, J. Q. (2007). *What matters for staying on-track and graduating in Chicago public high schools: A close look at course grades, failures, and attendance in the freshman year*. Consortium on Chicago School Research.

Aponte, L. C. (2026). *Sistema_De_Asistencia: Alerta temprana de ausentismo sobre School_Plus* [Software]. GitHub. https://github.com/caroaponte2614-tech/Sistema_De_Asistencia

Balfanz, R., & Byrnes, V. (2012). *The importance of being in school: A report on absenteeism in the nation's public schools*. Johns Hopkins University Center for Social Organization of Schools.

Barocas, S., Hardt, M., & Narayanan, A. (2023). *Fairness and machine learning: Limitations and opportunities*. MIT Press.

Breiman, L. (2001). Random forests. *Machine Learning, 45*(1), 5–32. https://doi.org/10.1023/A:1010933404324

Congreso de la República de Colombia. (2012, 17 de octubre). *Ley Estatutaria 1581 de 2012, por la cual se dictan disposiciones generales para la protección de datos personales*. Diario Oficial No. 48.587.

Miao, F., Holmes, W., Huang, R., & Zhang, H. (2021). *AI and education: Guidance for policy-makers*. UNESCO. https://doi.org/10.54675/PCSP7350

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., & Duchesnay, É. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research, 12*, 2825–2830.

Saito, T., & Rehmsmeier, M. (2015). The precision-recall plot is more informative than the ROC plot when evaluating binary classifiers on imbalanced datasets. *PLOS ONE, 10*(3), Artículo e0118432. https://doi.org/10.1371/journal.pone.0118432