DIPLOMADO EN INTELIGENCIA ARTIFICIAL · 20 SESIONES · 50 HORAS

PROYECTO FINAL INTEGRADO

Alerta temprana de ausentismo escolar con IA sobre la plataforma School_Plus

Presentado por: Leidy Carolina Aponte

Disciplina: Educación (gestión académica) + Ingeniería de software

Speaker: Ing. Winder Osorio Villalobos · **Fecha:** 27 de octubre de 2026

Repositorio del proyecto (autoría): github.com/caroaponte2614-tech/Sistema_De_Asistencia

"La IA es el MEDIO. El PROBLEMA es el FIN."

> **Resumen ejecutivo.** School_Plus ya registra la asistencia con QR dinámico (cada registro queda en base de datos con estado, método, celular y hora). El problema que sigue sin resolverse es que **el ausentismo se detecta tarde**: coordinación se entera cuando el estudiante ya perdió el 20 % de las clases. Este proyecto usa esos datos para **predecir, en la semana 8, qué estudiantes caerán por debajo del 80 % de asistencia en las semanas 9-16**. El modelo (Random Forest) detecta **87 % de los casos en riesgo** frente al **52 %** de la regla manual que usa hoy coordinación, y la IA generativa redacta los mensajes y planes de intervención que el docente revisa antes de enviar.

Los 7 entregables tratan el MISMO problema y forman una sola historia: Problema → IA generativa → Datos → Modelo → Evaluación → Ética y negocio → Presentación.

ENTREGABLE 1 · FICHA DEL PROBLEMA

Peso 10 %

Complejidad: básica | Sesiones 1-2 | Archivo: 01_FICHA_PROBLEMA.pdf

1. Contexto

Institución educativa de básica secundaria y media (grados 6.° a 11.°, jornadas mañana y tarde). Uso **School_Plus**, plataforma propia (Spring Boot 4, Java 21, MySQL) con roles de administrador, rectoría, coordinador, docente y estudiante. Su módulo central es la **asistencia con QR dinámico**: el docente proyecta un QR firmado con HMAC que rota cada 15 s, el estudiante lo escanea desde su celular vinculado y, al cerrar la sesión, quien no se registró queda ausente.

2. Problema

Qué no funciona hoy: la asistencia ya se captura bien, pero **nadie la lee a tiempo**. Coordinación revisa los reportes (exportados a Excel/CSV) a ojo, una vez por semana o al cierre del periodo, y aplica una regla informal: "alertar si el estudiante tiene menos de 85 % o tres fallas seguidas". Cuando la alerta llega, el estudiante ya acumula ausencias que comprometen el periodo; las alertas tempranas que se pierden terminan en pérdida de materias o deserción.

Cómo se detecta: porcentaje de asistencia por debajo del 80 % (umbral académico de pérdida por fallas), rachas de ausencias, tardanzas repetidas y quejas de acudientes que "no fueron avisados".

HOY	QR registra asistencia	→	Reporte en Excel	→	Coordinación revisa a ojo (semanal / fin de periodo)	→ Alerta tardía: el estudiante ya está por debajo del 80 %
DESEADO	QR registra asistencia	→	Modelo calcula riesgo cada semana	→	Aviso en la campanita del docente y de coordinación	→ IA generativa redacta mensaje y plan; el docente aprueba y actúa

3. Datos disponibles

Fuente (tabla de School_Plus)	Campos útiles	Acceso
`asistencia_registro`	estado (PRESENTE, TARDE, AUSENTE, JUSTIFICADO), método (QR, CÓDIGO, MANUAL, CIERRE), hora, observación	Exportación CSV/Excel en `/docencia/asistencia/reportes`
`asistencia_sesion`, `clase_horario`	día, franja horaria, tolerancia, hora de referencia	Base MySQL (lectura)
`clase`, `clase_inscripcion`	grado, grupo, periodo, asignatura	Base MySQL (lectura)
`asistencia_dispositivo`	cambios de celular solicitados/aprobados	Base MySQL (lectura)

4. Objetivo (cuantificable)

En la **semana 8** del periodo, identificar a los estudiantes que terminarán las semanas 9-16 con **asistencia < 80 %**, con **sensibilidad (recall) ≥ 80 %** y mejor precisión que la regla manual actual, y reducir de ~6 h a ~1,5 h semanales el tiempo de revisión de coordinación.

5. Restricciones

- **Técnicas:** el colegio no tiene GPU ni presupuesto de nube; el modelo debe correr en el mismo servidor local, en minutos. Un periodo da pocos casos positivos (~100 por cada 480 estudiantes).
- **Éticas:** son menores de edad; una alerta no puede convertirse en etiqueta ni en sanción. Siempre decide una persona.
- **Legales:** Ley 1581 de 2012 (protección de datos personales en Colombia) y datos de menores: finalidad educativa, minimización y no compartir datos identificables con servicios externos.

6. Éxito

Funciona si: (a) recall ≥ 80 % en datos de prueba; (b) supera a la regla manual en recall y F1; (c) diferencias de desempeño entre grupos (con/sin celular, jornada) identificadas y controladas; (d) el docente recibe la alerta antes de la semana 9 con una explicación que entiende.

ENTREGABLE 2 · SOLUCIÓN CON IA GENERATIVA

Peso 10 %

Complejidad: básica | Sesiones 3-4 | Herramientas: Claude, ChatGPT, Perplexity | Archivo: 02_IA_GENERATIVA.docx

1. Prompts iniciales (diseñados para este problema)

```
P1 · Lectura del reporte
Eres coordinador académico de un colegio. Te paso el reporte de asistencia exportado de
School_Plus (CSV: estudiante, clase, presentes, tardes, ausentes, justificados, %).
1) Lista los estudiantes por debajo del 85 %, ordenados de peor a mejor.
2) Señala patrones (días, clases o tardanzas que se repiten).
3) No inventes datos: si algo no está en el CSV, di "no hay dato".
```

```
P2 · Mensaje al acudiente
Redacta un mensaje corto y respetuoso para el acudiente de un estudiante de grado {grado}.
Datos: asistencia {pct} %, {aus} ausencias en las últimas 2 semanas, {tardes} tardanzas.
Tono: cercano, sin culpar, sin diagnósticos. Termina invitando a una reunión.
Máximo 90 palabras. No incluyas el nombre del estudiante (lo agrega el docente).
```

```
P3 · Clasificar justificaciones
Clasifica cada observación de falta justificada en: SALUD, FAMILIAR, TRANSPORTE,
ACADÉMICA/DEPORTIVA u OTRA. Devuelve una tabla "observación | categoría | confianza".
```

```
P4 · Plan de intervención
Con este perfil de asistencia (semanas 1-8: {resumen}), propone 3 acciones escalonadas
(docente → coordinación → orientación) con responsable y plazo. Sin etiquetar al estudiante.
```

2. Ejemplos de entrada/salida (obtenidos con Claude)

Entrada P2: grado 8.°, asistencia 76 %, 6 ausencias en 2 semanas, 4 tardanzas.

> "Buenos días. Le escribimos desde la coordinación de grado 8.° porque en las últimas dos semanas notamos varias ausencias (6) y algunas llegadas tarde. Queremos entender si hay alguna situación en la que podamos apoyar desde el colegio. Nos gustaría conversar con usted esta semana; ¿qué día le queda mejor? Quedamos atentos. Cordialmente, Coordinación académica."

Entrada P3: "Cita médica", "Calamidad familiar", "Se le varó el bus", "Representación deportiva", "no vino".

> Cita médica → SALUD (alta) · Calamidad familiar → FAMILIAR (alta) · Se le varó el bus → TRANSPORTE (alta) · Representación deportiva → ACADÉMICA/DEPORTIVA (alta) · "no vino" → OTRA (baja: *no es una justificación, revisar*).

Entrada P1 con un CSV de 40 filas: identificó correctamente los 7 estudiantes bajo 85 % y señaló que "las ausencias se concentran en lunes y viernes". Con un CSV de 2 000 filas omitió estudiantes y redondeó porcentajes de forma distinta a School_Plus.

3. Análisis de capacidades

Lo hace bien	Dónde falla
Redacción empática y adaptada al acudiente (P2); clasificación de textos libres (P3); proponer acciones razonables (P4); explicar patrones en lenguaje natural.	Cálculos sobre muchos datos (omite filas, redondea distinto); no recuerda el historial de semanas anteriores; no da probabilidades calibradas; con datos ambiguos "inventa" causas si el prompt no lo prohíbe.

4. Limitaciones: por qué la IA generativa sola no basta

- **No predice:** describe el pasado, no estima quién caerá en las próximas 8 semanas.
- **No es reproducible:** el mismo CSV puede dar listas distintas; no sirve como fuente de verdad.
- **Privacidad:** pegar reportes con nombres de menores en un chat externo viola la minimización de datos. Los prompts se diseñaron para trabajar **sin nombres**.

5. Próximos pasos

Separar funciones: un **modelo predictivo local** (Entregable 4) calcula el riesgo con los datos completos, y la IA generativa se usa solo para **redactar y explicar** a partir de un resumen anonimizado, con revisión humana antes de enviar.

ENTREGABLE 3 · ANÁLISIS DE DATOS

Peso 20 %

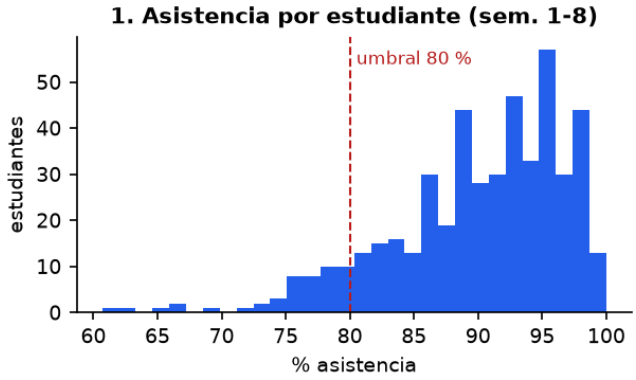
Complejidad: media | Sesiones 5-6 | Python: Pandas, Matplotlib | Archivos: 03_ANALISIS_DATOS.xlsx + .pdf

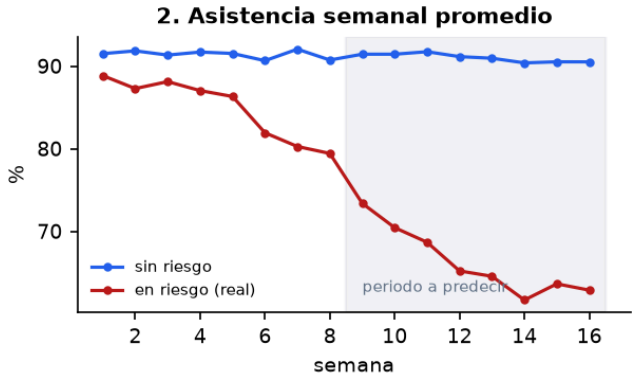
Origen de los datos. School_Plus entró en uso este semestre y aún no tiene un periodo completo cerrado. Para no exponer datos de menores, el análisis usa un **dataset sintético con el esquema exacto de `asistencia_registro`** (480 estudiantes, 60 clases, 16 semanas), generado con supuestos documentados en el notebook. El pipeline lee el CSV que exporta School_Plus, así que se reemplaza por los datos reales sin cambiar código.

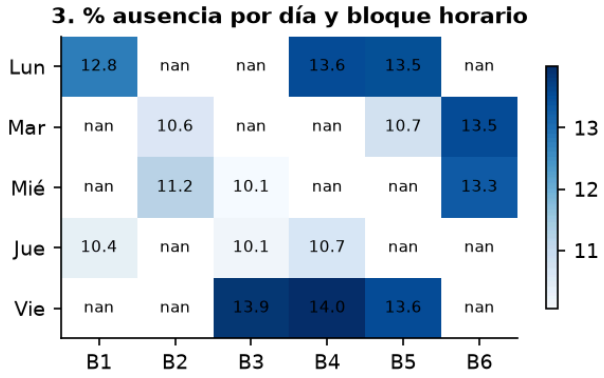
1. Exploración (EDA)

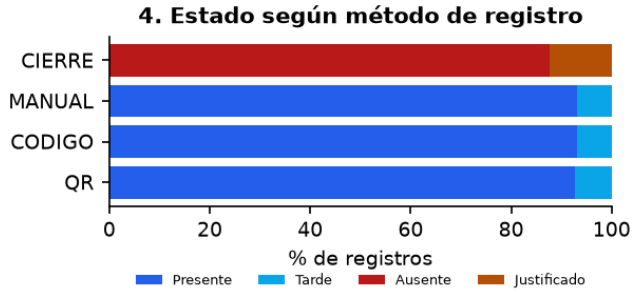
Dimensión	Valor	Hallazgo
Filas × columnas	115 891 × 11	Un registro por estudiante y sesión
Estudiantes / clases	480 / 60	Grados 6.° a 11.°, grupos A (mañana) y B (tarde)
Tipos	8 categóricas, 3 numéricas	estado y método son categorías cerradas (CHECK en BD)
Duplicados	691 (0,6 %)	Dos exportaciones con rangos de fechas solapados
Nulos `observacion`	98,3 %	Estructural: solo existe en justificadas
Nulos `dispositivo_id`, `ip`	20,9 %	Estructural: registros MANUAL y CIERRE no tienen celular
Distribución de estados	Presente 80,2 % · Ausente 11,9 % · Tarde 6,3 % · Justificado 1,7 %	
Distribución de métodos	QR 68,1 % · Cierre 13,6 % · Código 11,0 % · Manual 7,3 %	

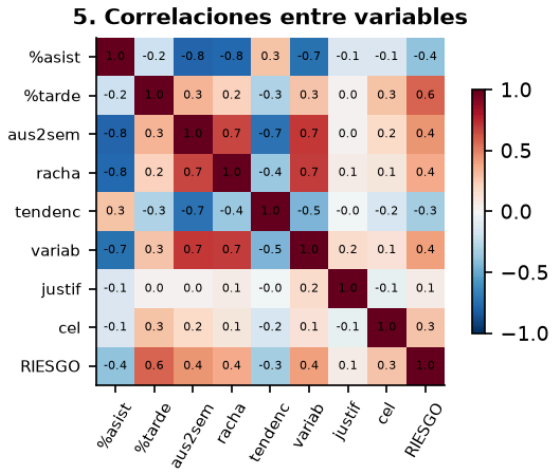
2. Visualizaciones

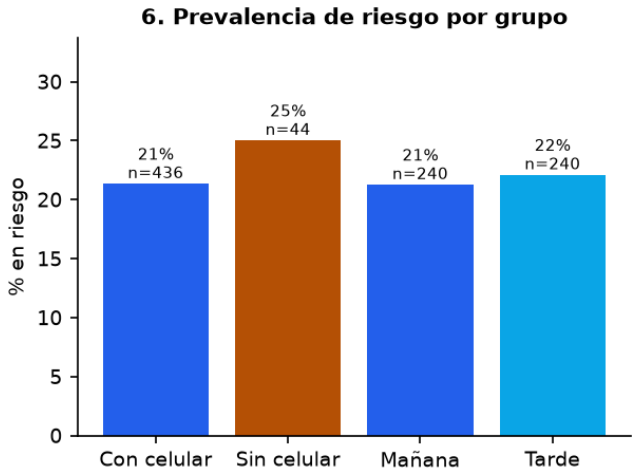












G1: la mayoría está sobre 90 %, con una cola bajo el umbral. G2: quienes terminan en riesgo ya vienen cayendo antes de la semana 8: hay señal para predecir. G3: más ausencia en lunes, viernes y último bloque. G4: CIERRE concentra las ausencias; MANUAL corresponde a estudiantes sin celular. G5: la tardanza es la variable más correlacionada con el riesgo (0,58). G6: prevalencia por grupo.

3. Limpieza (documentada)

Transformación	Motivo
Eliminar 691 filas duplicadas → 115 200	Exportaciones solapadas inflaban las ausencias
Mantener nulos estructurales (no imputar)	Un MANUAL sin celular no es un dato faltante
Eliminar la columna `ip`	Dato personal sin valor predictivo (minimización)
Variables derivadas: asistió, cuenta, tarde, ausente	Mismo cálculo que School_Plus: (presentes + tardes) / (total − justificadas)
Agregar por estudiante: semanas 1-8 → variables; 9-16 → etiqueta	Evitar fuga de información del futuro

4. Estadísticas clave

Asistencia media **90,0 %** (mediana 91,6 %, percentil 10: 80,5 %). Tardanza media 7,5 % de las asistencias. **104 de 480 estudiantes (21,7 %)** terminan en riesgo. Correlación con el riesgo: tardanza **+0,58**, % asistencia −0,39, tendencia semanal −0,32, cambios de celular +0,27.

5. Sesgos iniciales

- **Desbalance de clases:** 21,7 % positivos → se usa `class_weight="balanced"` y se mide recall/F1, no exactitud.
- **Sesgo de registro en estudiantes sin celular (9,2 %):** su ausencia registrada es 18,6 % contra 11,5 % del resto. Parte de esa diferencia no es ausentismo real: si el docente olvida marcarlo a mano, el cierre lo deja ausente. **La etiqueta misma está sesgada contra este grupo.**
- Jornada: prevalencia similar (mañana 21,2 %, tarde 22,1 %); no hay desequilibrio relevante.

6. Dataset preparado

`data/asistencia_limpio.csv` (115 200 registros) y `data/dataset_modelo_limpio.csv` (480 estudiantes × 9 variables + etiqueta + atributos de grupo solo para auditoría).

ENTREGABLE 4 · MODELO O PROTOTIPO DE IA

Peso 25 %

Complejidad: media | Sesiones 7-8 | Opción C (avanzada): modelo predictivo con ML, comparado con la Opción A (reglas)

Archivos: 04_MODELO.ipynb + 04_MODELO.pkl

1. Descripción

Clasificador binario: **¿el estudiante terminará las semanas 9-16 con asistencia < 80 %?** Se entrena con 9 variables calculadas sobre las semanas 1-8. Se comparan **Regresión logística** (interpretable) y **Random Forest** (no lineal) contra la **regla manual** de coordinación como línea base (Opción A: *% < 85 o racha ≥ 3 ausencias*).

Variable	Qué mide	Variable	Qué mide
pct_asistencia	% como lo calcula School_Plus	variabilidad_semanal	desviación del % semana a semana
pct_tardanza	tardes / asistencias	justificadas	número de faltas justificadas
ausencias_ult2sem	ausencias en semanas 7-8	pct_lunes_viernes_aus	ausencia en lunes y viernes
racha_max_ausencias	máximo de faltas seguidas en una clase	cambios_celular	solicitudes de cambio de celular
tendencia_semanal	pendiente de la recta del % semanal	*Excluidas a propósito:* grado, jornada, sin_celular (solo para auditar equidad)	

2. Código limpio y comentado (extracto del notebook)

```
# Variables de las semanas 1-8, etiqueta de las semanas 9-16 (sin fuga del futuro)
h1, h2 = limpio[limpio.semana <= 8], limpio[limpio.semana > 8]
X = h1.groupby("estudiante_id").apply(features)
y = (h2.groupby("estudiante_id").apply(pct) < 0.80).astype(int)

# 70/30 estratificado; validación cruzada de 5 particiones sobre el 70 %
Xtr, Xte, ytr, yte = train_test_split(X, y, test_size=0.3, stratify=y, random_state=7)
rf = RandomForestClassifier(n_estimators=300, max_depth=6, min_samples_leaf=5,
                            class_weight="balanced", random_state=7)
cross_val_score(rf, Xtr, ytr, cv=StratifiedKFold(5, shuffle=True), scoring="roc_auc")
rf.fit(Xtr, ytr)
joblib.dump({"modelo": rf, "features": FEATS, "umbral": 0.5}, "04_MODELO.pkl")
```

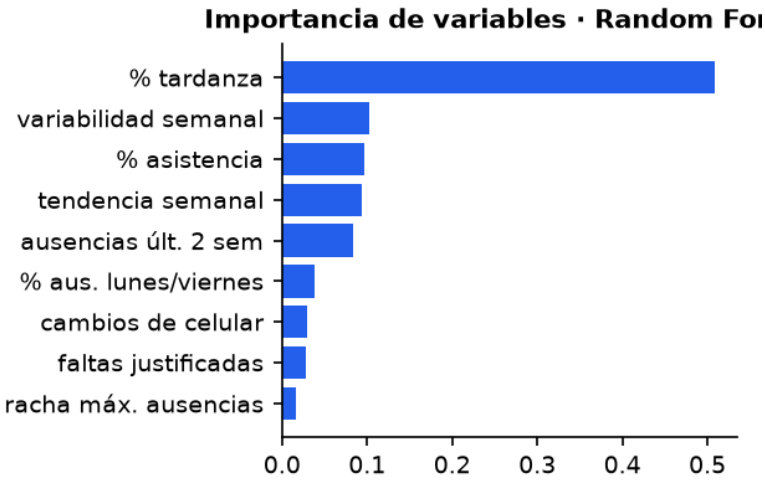
3. Entrenamiento y validación

Modelo	AUC validación cruzada (5 particiones, n = 336)
Regresión logística	0,916 ± 0,031
Random Forest	**0,919 ± 0,015** (más estable entre particiones) → **elegido**

4. Resultados y métricas (conjunto de prueba, n = 144, 31 en riesgo)

Modelo	Precisión	Recall	F1	AUC	Detectados / 31
Regla manual (coordinación)	0,46	0,52	0,49	—	16
Regresión logística	0,59	0,74	0,66	0,91	23
Random Forest (umbral 0,5)	**0,52**	**0,87**	**0,65**	**0,90**	**27**

Se prioriza el **recall**: en alerta temprana es peor no avisar sobre un estudiante que se va (falso negativo) que pedirle a un docente una conversación innecesaria (falso positivo).



5. Ejemplos de predicción

Estudiante	% asist. sem. 1-8	Tendencia (pp/sem)	Prob. de riesgo	Alerta	Realidad sem. 9-16
E0034	67,2 %	−7,9	1,00	Sí	En riesgo (43,3 %)
E0242	76,3 %	−8,4	0,95	Sí	En riesgo
E0029	93,1 %	−2,0	0,65	Sí	En riesgo (73,7 %): la regla manual no lo habría visto
E0355	95,8 %	−0,3	0,77	Sí	Sin riesgo (falso positivo)
E0268	95,8 %	−0,1	0,01	No	Sin riesgo

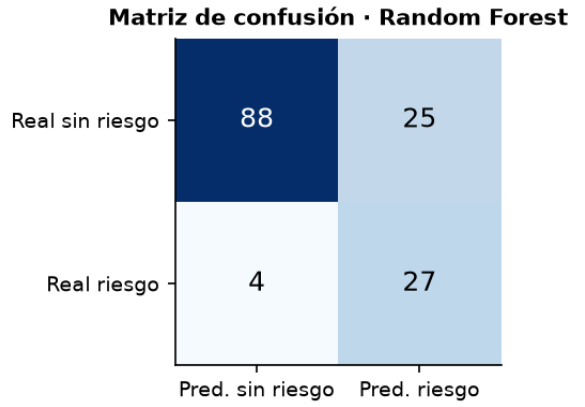
Integración en School_Plus (diseño): un job semanal (como el `CierreAutomaticoJob` que ya existe) exporta las variables, el modelo devuelve la probabilidad y `NotificadorAsistencia` envía el aviso a la campanita del docente y de coordinación. El estudiante no ve su puntaje.

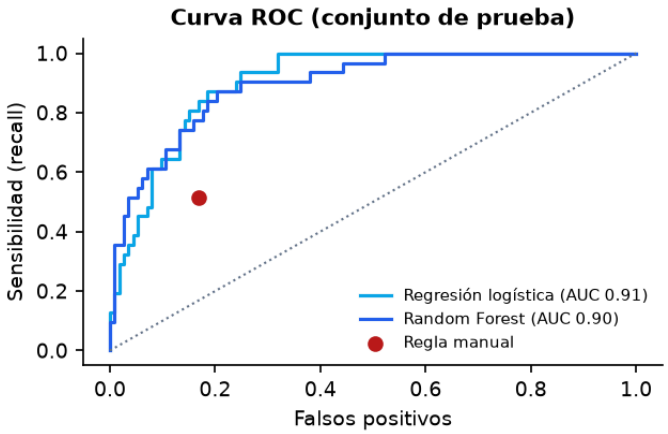
ENTREGABLE 5 · EVALUACIÓN DE RESULTADOS

Peso 15 %

Complejidad: media | Sesión 9 | Archivo: 05_EVALUACION_RESULTADOS.docx

1. Métricas técnicas





Random Forest: precisión 0,52 · recall 0,87 · F1 0,65 · AUC 0,90 · exactitud 0,80. Con umbral 0,4: recall 0,90 y precisión 0,47 (28 de 31 detectados, 32 falsas alarmas). La regla manual (punto rojo) queda por debajo de ambas curvas: **a igual tasa de falsas alarmas, el modelo detecta mucho más**.

2. Validación manual: 25 predicciones revisadas una a una

Se tomaron 25 estudiantes al azar del conjunto de prueba y se contrastó la predicción con su asistencia real de las semanas 9-16: **22 de 25 aciertos (88 %)**. Los 3 errores son falsos positivos **en el límite del umbral**: E0302 terminó con 80,0 % exacto, E0210 con 81,5 % y E0396 con 83,1 %. Ningún estudiante con caída fuerte quedó sin alerta en la muestra.

Caso	% sem. 1-8	Prob.	Pred.	Real sem. 9-16	Juicio del revisor
E0034	67,2	1,00	Riesgo	43,3 %	Correcto; caso evidente
E0171	82,2	0,94	Riesgo	49,6 %	Correcto; 10 ausencias en 2 semanas
E0262	85,7	0,62	Riesgo	48,7 %	Correcto; la regla manual no lo marcaba
E0403 (sin celular)	75,4	0,82	Riesgo	40,7 %	Correcto
E0302 (sin celular)	80,8	0,51	Riesgo	80,0 %	Falso positivo en el borde; aceptable
E0396	95,8	0,71	Riesgo	83,1 %	Falso positivo: tardanzas altas, pero asiste
+ 19 casos más (tabla completa en el notebook): 17 sin riesgo correctamente descartados, 1 en riesgo detectado (E0029) y 1 falso positivo en el borde (E0210).					

3. Casos edge: dónde falla el modelo

Caso	Qué pasó	Por qué
E0158 · prob. 0,13, real 76,9 %	Falso negativo	Su caída empieza en la semana 9: en las semanas 1-8 no hay ninguna señal. **Ningún modelo semanal puede verlo en la semana 8** → hay que re-calcular cada semana.
E0144 · prob. 0,08, real 79,8 %	Falso negativo	4 faltas justificadas y quedó a 0,2 pp del umbral: caso de frontera.
E0373 · prob. 0,98, real 85,5 %	Falso positivo con alta confianza	Cayó fuerte desde la semana 3 y luego se estabilizó. El modelo no sabe si hubo intervención: **una alerta exitosa "parece" un error**.
E0063 (sin celular) · prob. 0,21	Falso negativo	Caída tardía (semana 11) en un grupo con datos más ruidosos.

Equidad por grupo (prueba): con celular, recall 0,92 y falsos positivos 0,20; **sin celular, recall 0,60 y falsos positivos 0,45** (n = 16, muestra pequeña). Jornada mañana, recall 1,00; tarde, 0,73. Ver Entregable 6.

4. Comparación: ¿es mejor que hacerlo manualmente?

Criterio	Antes (regla manual)	Después (modelo)
Estudiantes en riesgo detectados (de 31)	16 (52 %)	**27 (87 %)**
Falsas alarmas	19	25
Momento de la alerta	Semanal o al cierre, según disponibilidad	Automática cada semana
Tiempo de coordinación	~6 h/semana revisando Excel	~1,5 h/semana revisando una lista priorizada

Sí es mejor: detecta 11 estudiantes más a cambio de 6 falsas alarmas adicionales, y cada falsa alarma cuesta una conversación de 10 minutos.

5. Lecciones aprendidas

- **Bien:** separar la captura (QR, determinista) de la predicción (ML) permitió reutilizar datos limpios; la tardanza resultó ser la señal temprana más fuerte.
- **A mejorar:** la importancia de la tardanza (0,51) depende de un supuesto de la simulación y debe confirmarse con datos reales; la etiqueta hereda el sesgo de registro de los estudiantes sin celular.

6. Recomendaciones para producción

1. Reentrenar con el primer periodo real cerrado y comparar contra estas métricas.
2. Calcular el riesgo **cada semana**, no solo en la semana 8 (resuelve casos como E0158).
3. Usar umbral 0,4 y mostrar los 3 factores que más pesaron en cada alerta.
4. Antes de usar el modelo, corregir el sesgo de origen: recordatorio al docente para marcar a mano a quien no tiene celular.
5. Registrar la intervención realizada para medir su efecto y no confundirla con un error del modelo.

ENTREGABLE 6 · ANÁLISIS ÉTICO Y DE NEGOCIO

Peso 10 %

Complejidad: básica | Sesiones 9-10 | Archivo: 06_ETICA_NEGOCIO.docx

Sección A · Ética (obligatoria)

1. Sesgos identificados: ¿es justo con todos los grupos? No del todo. Los estudiantes **sin celular** reciben más falsas alarmas (0,45 contra 0,20) y se detectan menos casos reales (recall 0,60 contra 0,92). La causa es un **sesgo de registro**: si el docente olvida marcarlos a mano, el cierre los deja ausentes, y el modelo aprende de esa etiqueta. Es un sesgo socioeconómico indirecto. **Medidas:** (a) el atributo "sin celular" se excluye de las variables y se usa solo para auditar; (b) antes de cerrar la sesión, School_Plus recuerda al docente a quiénes debe marcar a mano; (c) toda alerta de este grupo pasa por verificación manual; (d) auditoría de equidad cada periodo, con meta de diferencia de recall < 10 pp. También se vigila la diferencia entre jornadas (recall 1,00 contra 0,73).

2. Privacidad: ¿se protegen los datos? Sí, por diseño. El modelo corre **en el servidor del colegio** con identificadores UUID; se eliminó la IP y no se usan coordenadas; School_Plus guarda solo el SHA-256 del identificador del celular. La IA generativa recibe **resúmenes sin nombres** (P2 lo exige). Base legal: finalidad educativa bajo la Ley 1581 de 2012, informada a los acudientes. El estudiante no ve su puntaje y el puntaje no aparece en boletines.

3. Explicabilidad: ¿puedo explicar una decisión a un acudiente? Sí. Cada alerta muestra los hechos que la originaron, no el número del modelo: *"6 ausencias en las últimas 2 semanas, tardanzas en aumento, asistencia que baja 2 puntos por semana"*. La regresión logística, con coeficientes legibles (tardanza +1,75, % asistencia −0,76), sirve como modelo de contraste para explicar las decisiones del Random Forest.

4. Gobernanza: ¿quién responde si falla? El modelo **recomienda y una persona decide**. Responsable del modelo: administrador de School_Plus (reentrenamiento y auditoría). Responsable de cada acción: el docente y coordinación. Rectoría aprueba el uso y revisa la auditoría de equidad cada periodo. Prohibido usar la alerta para sancionar, calificar o negar cupos. Si una auditoría encuentra una brecha mayor a la meta, el modelo se suspende y se vuelve a la regla manual.

Sección B · Negocio

1. ROI estimado (12 meses). Supuestos a validar: costo hora de personal $35 000 COP; desarrollo e integración 80 h; el modelo corre en el servidor existente.

Concepto	Valor
Inversión: 80 h de desarrollo + API de IA generativa (~$50 000/mes)	$2 800 000 + $600 000 = **$3 400 000**
Ahorro: ~38 h/mes × $35 000 × 10 meses lectivos	**$13 300 000**
ROI en horas recuperadas	≈ **3,9 veces** la inversión (sin contar la retención de estudiantes)

2. Ahorro de tiempo: coordinación pasa de 6 h a 1,5 h semanales (18 h/mes); 20 docentes ahorran ~1 h/mes cada uno redactando mensajes a acudientes con IA generativa (20 h/mes). Total ≈ **38 h/mes**.

3. Impacto operacional: se pasa de una revisión reactiva de Excel a una lista semanal priorizada en la campanita. Se crea una ruta definida: docente → coordinación → orientación.

4. Riesgos (matriz abajo). **5. Plan de implementación:** (1) piloto en 2 grados durante un periodo, en paralelo con la regla manual; (2) reentrenar con datos reales y auditar equidad; (3) integrar el job semanal y los avisos en School_Plus; (4) capacitar a docentes en la lectura de alertas (1 h); (5) extender a toda la institución con revisión de métricas cada periodo.

Matriz de riesgos

Riesgo	Prob.	Impacto	Mitigación
Etiquetar o estigmatizar al estudiante	Media	Alto	Puntaje invisible para el estudiante; prohibido usarlo para sancionar
Sesgo contra estudiantes sin celular	Alta	Alto	Recordatorio de marcado manual, verificación humana, auditoría por grupo
Desempeño menor con datos reales	Media	Medio	Piloto en paralelo con la regla manual; reentrenar cada periodo
Fatiga por falsas alarmas	Media	Medio	Umbral ajustable; máximo de alertas por docente; mostrar los motivos
Fuga de datos a la IA generativa	Baja	Alto	Solo resúmenes anonimizados; sin nombres ni IDs
Deriva del modelo (cambios de horario o de política)	Media	Medio	Monitorear recall cada periodo y suspender si baja de 0,75

ENTREGABLE 7 · PRESENTACIÓN EJECUTIVA

Peso 10 %

Complejidad: básica | Sesiones 19-20 | 15 min · 16 diapositivas | PowerPoint / Gamma.app + video de 3-5 min | Archivo: 07_PRESENTACION.pptx

Narrativa para un público no técnico (rectoría, docentes, acudientes): **"Ya sabemos quién falta; ahora sabemos quién va a dejar de venir."**

Bloque	Diapositivas	Contenido y visual de apoyo	Min
1. Portada	1	Título, autor, disciplina, diplomado	0,5
2. Problema	2-3	Historia de un estudiante que "se fue sin que nadie lo notara"; flujo actual vs. deseado	2
3. Datos	4-5	Qué registra School_Plus con el QR; G2 (la caída se ve antes de la semana 8)	2
4. Solución	6-8	IA generativa (mensaje al acudiente); modelo en una frase; demo de la alerta en la campanita	3
5. Resultados	9-11	"27 de 31 contra 16 de 31"; curva ROC simplificada; un caso edge contado como historia	3
6. Impacto	12-14	38 h/mes, ROI ≈ 3,9 veces, ética: "la IA recomienda, la persona decide"	2,5
7. Conclusiones	15-16	Qué aprendimos, plan piloto, preguntas	2

Video de 4 min (resumen ejecutivo): 0:00 el problema en 30 s → 0:30 recorrido por School_Plus (QR en vivo) → 1:30 la alerta y el mensaje generado → 2:30 los resultados en una cifra → 3:20 ética y siguiente paso.

Defensa: preguntas probables y respuesta

Pregunta	Respuesta
¿Los datos son reales?	Son sintéticos con el esquema real; el pipeline lee el CSV de School_Plus y el piloto los reemplaza. Así se evitó exponer datos de menores.
¿Por qué Random Forest y no algo más simple?	Validación cruzada más estable (±0,015) y mayor recall. La regresión logística queda como modelo explicable de contraste.
¿Y las falsas alarmas?	Cuestan una conversación de 10 minutos; un falso negativo cuesta un estudiante perdido.
¿Puede discriminar?	Sí, ya lo medimos (estudiantes sin celular) y está mitigado y auditado cada periodo.

ANEXO · CUMPLIMIENTO DE RÚBRICA, HERRAMIENTAS Y ENTREGA

Matriz de cumplimiento (todos los criterios del marco)

Entregable (peso)	Criterio evaluado	Dónde se cumple
1 · Ficha (10 %)	Problema claramente definido	E1 §2, flujo actual vs. deseado
	Datos identificados y accesibles	E1 §3: tablas y ruta de exportación
	Objetivo cuantificable	E1 §4: recall ≥ 80 %, 6 h → 1,5 h
	Restricciones realistas	E1 §5: técnicas, éticas, legales
2 · IA generativa (10 %)	Prompts específicos	E2 §1: P1-P4
	Entrada/salida reales	E2 §2
	Análisis honesto de limitaciones	E2 §3-4
	Reflexión sobre pasos siguientes	E2 §5
3 · Datos (20 %)	EDA completo	E3 §1: dimensiones, tipos, nulos, duplicados
	4-6 visualizaciones	E3 §2: 6 gráficos
	Limpieza documentada	E3 §3
	Dataset final preparado	E3 §6 + /data
4 · Modelo (25 %)	Modelo ejecutable	04_MODELO.ipynb + .pkl
	Método apropiado	E4 §1: Opción C con línea base Opción A
	Métricas reportadas	E4 §3-4
	Ejemplos de predicción	E4 §5
5 · Evaluación (15 %)	Validación manual	E5 §2: 25 casos, 22 aciertos
	Casos edge	E5 §3
	Comparación antes/después	E5 §4
	Recomendaciones concretas	E5 §6 (también lecciones, §5)
6 · Ética y negocio (10 %)	Sesgos analizados	E6-A §1, medidos por grupo
	Privacidad	E6-A §2
	Explicabilidad	E6-A §3
	Análisis ético transparente	E6-A §4 + B (ROI, tiempo, impacto, riesgos, plan) + matriz de riesgos
7 · Presentación (10 %)	Narrativa clara	E7: guion en 7 bloques
	Visualizaciones de apoyo	G2, ROC, flujo, demo
	Timing de 15 min	E7: 15 min, 16 diapositivas + video de 4 min
	Defensa de preguntas	E7: preguntas preparadas

Herramientas usadas (mínimo viable del marco)

Para todos: Claude / ChatGPT, Google Drive, Word, PowerPoint / Gamma.app. **Datos:** Excel, Python (Pandas, Matplotlib) en VS Code / Google Colab. **Modelo:** Scikit-learn, joblib, GitHub (repositorio School_Plus). **Prototipo:** School_Plus (Spring Boot), que hace las veces de app de demostración (alternativa del marco a Streamlit o Hugging Face Spaces).

Estructura de entrega

```
Sistema_De_Asistencia/entregable_ia/
├── 01_FICHA_PROBLEMA.pdf
├── 02_IA_GENERATIVA.docx
├── 03_ANALISIS_DATOS.xlsx          03_ANALISIS_DATOS.pdf  (reporte visualizado)
├── 04_MODELO.ipynb                 04_MODELO.pkl          (Random Forest + variables + umbral)
├── 05_EVALUACION_RESULTADOS.docx
├── 06_ETICA_NEGOCIO.docx
├── 07_PRESENTACION.pptx            (+ video de 4 min)
├── README.md                       (cómo abrir y ejecutar: pip install pandas scikit-learn
│                                    matplotlib joblib; abrir el notebook y ejecutar todo)
└── data/  asistencia_original.csv · asistencia_limpio.csv · dataset_modelo_limpio.csv
```

Plataforma: GitHub: https://github.com/caroaponte2614-tech/Sistema_De_Asistencia (carpeta entregable_ia/). Los commits donde participó la IA llevan Co-Authored-By: Claude.

> **Integración:** los 7 entregables hablan del mismo problema, el ausentismo que se detecta tarde, sobre la misma plataforma, School_Plus, y con los mismos datos, `asistencia_registro`. Cada uno toma el resultado del anterior.